

Integrasi Neural Network

(Python Flask REST API) dengan Laravel

Pada Aplikasi Web Sistem Wadah Aspirasi Masyarakat (SWARA)

Laporan Pemrograman Sistem Cerdas

1. Latar Belakang

Kualitas pelayanan publik sangat bergantung pada kecepatan dan ketepatan instansi dalam menanggapi keluhan masyarakat. Seiring kemudahan teknologi, volume laporan pengaduan yang masuk terus meningkat setiap harinya. Namun, proses pengelolaan laporan ini sering kali masih terkendala oleh sistem peninjauan manual. Petugas harus membaca teks pengaduan satu per satu untuk menentukan kategori masalah—seperti Infrastruktur, Kebersihan, Keamanan, Pelayanan, maupun Kesehatan—sekaligus menilai seberapa mendesak tingkat urgensi penanganannya. Proses manual ini memakan banyak waktu dan berpotensi menunda tindak lanjut perbaikan di lapangan.

Untuk mengatasi kendala efisiensi tersebut, dikembangkan pendekatan otomatisasi menggunakan sistem cerdas yang mampu membaca dan memilah teks keluhan secara mandiri. Penerapan pemrosesan bahasa alami (TF-IDF) dipadukan dengan algoritma Feedforward Neural Network berbasis Multi-Layer Perceptron (MLP) menjadi solusi yang relevan. Model dilatih menggunakan dataset sebanyak 687 data pengaduan bertema lokal Purwokerto/Banyumas dengan distribusi kategori yang seimbang.

Melalui penerapan sistem cerdas klasifikasi teks ini, diharapkan setiap laporan yang masuk dapat langsung terpetakan secara otomatis dan real-time, sehingga respons penanganan masalah di masyarakat menjadi jauh lebih terarah dan efisien.

2. Ringkasan Arsitektur Sistem Cerdas

Sistem Pemantauan Pengaduan Masyarakat (SWARA) dirancang menggunakan arsitektur Decoupled (terpisah) untuk memisahkan logika antarmuka pengguna dengan komputasi kecerdasan buatan. Pendekatan ini menjamin performa web tetap ringan, aman, dan sangat kompatibel untuk dijalankan pada perangkat lokal dengan spesifikasi standar.

Komponen	Teknologi	Fungsi Utama
Model & REST API	Python, Scikit-Learn, Flask, Joblib	Memuat model Neural Network (.pkl), menerima data teks dari Laravel, melakukan ekstraksi fitur TF-IDF, dan mengembalikan klasifikasi dalam bentuk JSON.
Aplikasi Web (Frontend)	Laravel, Tailwind CSS, Blade	Menyediakan form pengaduan responsif, mengirim HTTP POST request ke server Python, dan menampilkan badge kategori & urgensi hasil prediksi.

3. Dataset Pengaduan

3.1 Struktur dan Komposisi Data

Dataset disusun dalam format spreadsheet .csv dengan tiga kolom: text_laporan (fitur input kalimat bebas), kategori (target label), dan urgensi (skala prioritas). Seluruh dataset terdiri dari 687 baris data pengaduan yang mencerminkan permasalahan nyata di wilayah Purwokerto/Banyumas.

Distribusi Label Kategori (Total: 687 data):

Kategori	Jumlah Data	Proporsi
Kesehatan	138	20,1%
Kebersihan	138	20,1%
Infrastruktur	138	20,1%
Keamanan	137	19,9%
Pelayanan	136	19,8%
Total	687	100%

Distribusi Label Urgensi:

Urgensi	Jumlah Data	Proporsi
Sedang	427	62,2%
Tinggi	212	30,9%
Rendah	48	6,9%
Total	687	100%

3.2 Contoh Data Pengaduan

Berikut beberapa contoh data pengaduan dari dataset yang digunakan:

Teks Laporan	Kategori	Urgensi
Jalan setapak menuju fasilitas kesehatan di daerah Kembaran rusak berat, sulit dijangkau warga yang membutuhkan.	Infrastruktur	Tinggi
Bak penampungan sampah sementara di kawasan Sokaraja sudah overkapasitas dan meluber ke badan jalan raya.	Kebersihan	Sedang
Bantuan sosial untuk korban bencana di kawasan Rawalo belum tersalurkan selama dua minggu, warga kelaparan.	Pelayanan	Tinggi
Aksi premanisme berkedok pengamanan proyek konstruksi dekat RSUD Banyumas meresahkan pekerja bangunan.	Keamanan	Tinggi
Mohon diadakan pemeriksaan kesehatan gratis berkala di daerah Kembaran untuk deteksi dini penyakit kronis.	Kesehatan	Rendah

4. Alur Langkah Pembuatan Sistem

Tahap A: Penyiapan Corpus & Dataset Keluhan

Dataset disusun dalam format .csv dengan tiga kolom wajib: text_laporan, kategori, dan urgensi. Total 687 baris data dikumpulkan dengan muatan lokal Purwokerto/Banyumas, menghasilkan distribusi kategori yang sangat seimbang (136–138 data per kelas). Distribusi urgensi lebih dominan pada label Sedang (62,2%), diikuti Tinggi (30,9%), dan Rendah (6,9%).

Tahap B: Pelatihan Model Neural Network (Google Colab)

Teks laporan dibersihkan melalui case folding lalu dikonversi menggunakan TfidfVectorizer dengan konfigurasi ngram_range=(1, 2) dan sublinear_tf=True untuk menangkap konteks frasa dua kata.

Dua model Pipeline dilatih secara terpisah:

Parameter	Model Kategori	Model Urgensi
Hidden Layers	(100, 50)	(100, 50)
Aktivasi	ReLU	ReLU
Solver	Adam	Adam
Learning Rate	Constant (0.001)	Adaptive (0.001)
Max Iterasi	1000	2000
ngram_range	(1, 2)	(1, 2)
sublinear_tf	True	True
random_state	42	42

Model dibungkus menggunakan Pipeline untuk menyatukan langkah vektorisasi TF-IDF dan klasifikasi MLP, kemudian diekspor menjadi file biner .pkl menggunakan pustaka Joblib.

Tahap C: Pembuatan Layanan Micro-Service API (Flask Python)

File app.py bertugas memuat kedua model .pkl ke memory lokal saat runtime. Flask membuka dua endpoint utama:

- GET /api/status — memeriksa apakah kedua model berhasil dimuat.
- POST /api/klasifikasi — menerima payload JSON berisi field laporan, memprediksi kategori dan urgensi secara paralel, lalu mengembalikan respons JSON berisi hasil prediksi kategori dan urgensi.

Seluruh alur prediksi diserahkan sepenuhnya kepada model AI tanpa aturan if-else manual, memastikan konsistensi dan kemudahan pemeliharaan kode.

Tahap D: Pembangunan Antarmuka & Jembatan Komunikasi (Laravel 11)

Arsitektur MVC Laravel digunakan dengan PengaduanController sebagai pengontrol alur. Facades Http dari Illuminate\Support\Facades\Http digunakan untuk mengirim HTTP POST request ke port 5000 milik Python Flask. Hasil prediksi diteruskan ke tampilan Blade sebagai session flash data dan ditampilkan sebagai badge kategori dan urgensi secara otomatis.

5. Evaluasi Performa Model

5.1 Hasil Evaluasi Model Klasifikasi Kategori

Model kategori dievaluasi menggunakan data uji sebesar 20% dari total dataset (138 data). Hasil evaluasi menunjukkan performa yang sangat tinggi:

Kelas	Precision	Recall	F1-Score	Support
Infrastruktur	1.00	1.00	1.00	28
Keamanan	1.00	1.00	1.00	27
Kebersihan	1.00	1.00	1.00	28
Kesehatan	1.00	1.00	1.00	28
Pelayanan	1.00	1.00	1.00	27
Accuracy (Total)			1.00	138

Model kategori mencapai akurasi 100% pada data uji, dengan nilai precision, recall, dan F1-score sempurna di semua 5 kelas. Hal ini menunjukkan bahwa fitur kata-kata khas per kategori (misalnya kata “sampah” untuk Kebersihan atau “jalan” untuk Infrastruktur) sangat kuat dan konsisten dalam dataset, sehingga model mampu membedakan kelas secara sempurna.

5.2 Hasil Evaluasi Model Klasifikasi Urgensi

Model urgensi dievaluasi pada 138 data uji yang sama. Performa model urgensi lebih rendah dibandingkan model kategori karena distribusi label yang tidak seimbang dan penilaian urgensi bersifat lebih subjektif:

Kelas	Precision	Recall	F1-Score	Support
Rendah	0.00	0.00	0.00	10
Sedang	0.64	0.65	0.64	86
Tinggi	0.32	0.31	0.31	42
Accuracy (Total)			0.50	138

Akurasi model urgensi sebesar 50% menunjukkan tantangan yang lebih besar dalam klasifikasi urgensi. Kelas Rendah sama sekali tidak terdeteksi (F1-Score = 0.00) karena jumlah data yang sangat sedikit (hanya 48 dari 687 data, atau 6,9%). Kelas Sedang memiliki performa terbaik (F1-Score = 0.64) sesuai dominasinya dalam dataset.

5.3 Analisis & Rekomendasi Peningkatan Model Urgensi

Rendahnya performa model urgensi disebabkan oleh beberapa faktor:

- Ketidakseimbangan data: Label Rendah hanya 48 data (6,9%) dibanding Sedang 427 data (62,2%), sehingga model cenderung mengabaikan kelas minoritas.
- Subjektivitas label: Penilaian urgensi bersifat lebih subjektif dan kontekstual dibandingkan kategori topik, sehingga lebih sulit dipelajari hanya dari pola kata.
- Fitur teks belum cukup: Urgensi sering ditentukan oleh konteks situasional (misalnya “sudah dua minggu” atau “satu rumah habis terbakar”) yang memerlukan pemahaman semantik lebih dalam.

Rekomendasi peningkatan:

- Menambah data berlabel Rendah untuk menyeimbangkan distribusi, atau menerapkan teknik SMOTE/oversampling.
- Menerapkan `class_weight='balanced'` pada `MLPClassifier` agar model memberikan bobot lebih pada kelas minoritas.
- Menggunakan model berbasis Transformer (misalnya IndoBERT) untuk pemahaman konteks semantik yang lebih baik.

6. Kesimpulan & Saran

Sistem SWARA berhasil mengintegrasikan Neural Network berbasis Pipeline (TF-IDF + MLP) dengan arsitektur Flask REST API dan Laravel secara mulus. Pengujian komunikasi data membuktikan HTTP Status Code 200 OK diterima secara konsisten dari endpoint `/api/klasifikasi`.

Secara keseluruhan, model kategori mencapai performa sempurna (akurasi 100%) pada dataset uji berkat distribusi label yang seimbang dan karakteristik kosakata yang khas per kategori. Di sisi lain, model urgensi memerlukan penyempurnaan lebih lanjut karena ketidakseimbangan data dan sifat penilaian yang lebih subjektif (akurasi 50%).

Untuk pengembangan selanjutnya, disarankan:

- Memperbaiki dataset urgensi dengan penambahan data kelas Rendah dan penerapan teknik class balancing.
- Menambahkan fitur confidence score pada respons API agar petugas dapat mengetahui tingkat keyakinan model.
- Mengeksplorasi penggunaan model berbasis Transformer seperti IndoBERT untuk meningkatkan pemahaman konteks bahasa Indonesia yang lebih nuansatif.